



操作系統 (114 秋天)

吳俊峰

助理教授，國家楊明喬董大學

✉ cfwu417@cs.nycu.edu.tw

🌐 <https://cfwu417.github.io>

提醒- 紙 推介會

- 當您需要做演示時應該在線加入。
 - <https://nycu.webex.com/meet/cfwu417>
 - 歡迎大家參加每週五的線上論文報告會。
- 我們對演示的期望（6-8分鐘）：
 - 背景、趨勢（約2分鐘）
 - 相關作品、觀察與動機（約2分鐘）
 - 方法論概念（約3分鐘）
- 標準：
 - 動機要夠清晰。（從背景到相關工作，再到挑戰，要清楚地組織流程）
 - 讓演示更容易理解。（一些動畫可能會有幫助。）
 - 指出方法論的設計理念？（不要深入探討演算法，請擷取高階概念。）
 - 不要讓演講超過8分鐘




L1：作業系統回顧

議程

- 電腦系統組織
- 什麼是作業系統和Linux 內核
- 作業系統 結構
- 我們將討論哪些主題
 - 行程與中斷
 - 主記憶體管理
 - I/O 裝置和裝置驅動程式
 - 檔案系統
 - 作業系統的挑戰
 - 進階主題：圖形系統、深度推薦系統、鍵值資料庫、重複資料刪除、資料中心運算、虛擬化概念

電腦組織


- 簡介：計算設備、儲存設備（例如 DRAM）和I/O設備（例如 HDD、SDD 或網路設備）是三個主要的基本組件。
 - 軟體：程式、資料和指令的集合。
- 馮諾依曼建築：
 - CPU從記憶體中取得指令。
 - 然後，CPU解碼並執行該指令。
 - CPU 取得下一個資料（自動增加 PC）。
- 挑戰 沒有 操作系統：
 - CPU 將由一個行程獨自佔用。
 - Sol: 進程調度程序* CPU 應等待 I/O 設備。（1 ns 對比 100 us）。
 - Sol: 頁面錯誤處理程序和上下文切換* CPU 無法理解 I/O 裝置中的「檔案」。
 - Sol: 裝置驅動程式和檔案系統*



CPU 只做例行工作！


作業系統（OS）的角色

- 目標：軟體層（中間件）位於應用程式和電腦硬體之間。作業系統的作用是**協調和管理硬體裝置**。（例如，中央處理器，記憶，儲存裝置）。
- 作業系統角色：
 - 透明度：使用者做不是需要擔心關於**硬體管理階層**或者**爭贊**。
 - 資源分配器：**管理**中央處理器時間，記憶空間和輸入/輸出資源。
 - 控制程式：**防止錯誤**和不當使用的電腦。



作業系統的角色（數數。）

- 目標：軟體層（中介軟體）位於應用程式和電腦硬體之間。作業系統的作用是**協調**和**管理硬體裝置**。（例如，中央處理器，記憶，貯存裝置）。
- 知名成分：
 - 過程調度程序：公平地為應用程式分配資源。
 - 記憶體管理器：分配記憶體、定位頁面、回收記憶體。
 - 堵塞輸入/輸出層：管理輸入/輸出請求（合併 & 行程輸入/輸出）
 - 文件系統：定位檔案內容、分割設備、控制權限。




什麼是Linux內核

- Linux核心： 流程管理器包括 一個 **用 C 語言和彙編 代碼**。
- Linux 核心是一個行程嗎？**不**，不完全是。
 - 每個行程都應有自己的虛擬位址空間。


虛擬位址空間讓程式設計4KB更簡單！

頁
頁
桌子
頁框 (4KB)





什麼是Linux核心（計數。）

- Linux核心：流程管理器包括一個 **用C** 的 **C** 語言和彙編代碼。
- Linux 核心是一個行程嗎？**不**，不完全是。
 - 每個行程都應有自己的虛擬位址空間。



什麼是Linux核心（計數）

- Linux核心：流程管理器包括一個 **用C** 的 **C** 語言和彙編 代碼。
- Linux 核心是一個行程嗎？不，不完全是。
 - 每個行程都應有自己的虛擬位址空間。
 - 核心作為**用戶進程的一部分**運行。（注意：所有行程的虛擬位址空間的**特定部分都指向**儲存核心程式碼的同一個實體**位址**。）
 - 還有一些核心進程負責監視系統狀態。（守護程式）



注意：CPU 切換到核心模式是為了存取作業系統代碼。
但是，CPU 不需要切換上下文！


如何觸發/請求核心服務

- 什麼時候做 CPU 跑步 核心：CPU 僅在某些特殊事件觸發時才運行核心。否則，它會運行用戶程式或保持空閒狀態。
- 特別的事件：
 - 硬體中斷（警報 訊號）
 - 計時器打斷
 - I/O中斷（例如，鍵盤，難的磁碟）
 - 軟體生成中斷（陷阱 或者 例外情況）
 - 具體的請求從使用者流程（系統調用，例如讀/寫）
 - 一些錯誤（例如，無效的記憶使用權 或者 頁故障）



綜合起來：高層概述

- 使用者空間：
 - 應用程式（例如 TensorFlow、Hadoop、資料庫、Pytorch）
 - 庫（例如，C/C++ 庫→ 進行記憶體分配）
- 核心空間：
 - 裝置驅動程式（與 I/O 裝置聯繫）
 - 核心內核
 - 流程管理
 - 記憶體管理
 - I/O管理



新興的I/O技術



NVMe M.2 固態硬碟



NVMe U.2 固態硬碟



英特爾傲騰固態硬碟



NVMe PCIe固態硬碟



三星 Z-NAND SSD




英特爾傲騰資料
中心
持久記憶體

動態隨機存取記憶體



NAND 閃光

慧與 非揮發性DIMM



高吞吐量
3.98 GB/秒

超低延遲
~5 我們

儲存類別
記憶

更快的
資料匯流排


2011

2017

現在

系統趨勢－重新思考作業系統

- 設備趨勢模糊了記憶體和儲存之間的界限。
- 貯存回覆時間漁獲向上和情境轉變開銷（1~10 us）。
- 這開賣的跑步文件系統變成批判的（例如，頁快取）。
- 巨大的記憶需求增加部署成本。（合適的頁面大小？）



議程



- 電腦系統組織
- 什麼是作業系統
- 高層概述
- 我們將涵蓋哪些主題
 - 行程與中斷
 - 主記憶體管理
 - I/O 裝置和裝置驅動程式
 - 檔案系統
 - 關閉到應用：圖形系統、深度推薦系統、鍵值資料庫、虛擬化概念

過程 & 打斷

- 過程
 - 什麼是流程，過程描述符，過程狀態圖（過程的生命週期）
 - 多道程式設計和多工處理 上下文切換
- 中央處理器 調度：
 - 優先權、時間片
 - 在）（Linux 2.4 ~ 2.6）
 - O(1) SCHED_Normal （Linux 版本 2.6.0 至 2.6.22）
 - 完全地公平的調度器（糧安委）（後 Linux 2.6.22）
 - 即時的調度
- 中斷：
 - 軟體中斷：如何系統稱呼作品。也, 如何到實施它。
 - 硬體中斷：如何中斷處理程式（或者打斷服務常規）作品。
- 進步研究主題：
 - （1）重新思考上下文切換
 - （2）重新思考流程狀態圖表


主記憶體管理

- 實體記憶體
 - 身體的記憶分配（夥伴系統）
 - 板層
- 虛擬的記憶
 - 分頁（頁桌子走），巨大的頁
 - 頁過錯處理程式
 - 頁替換（LRU 和其他）
 - 交換
- 記憶體層次結構（快取、記憶體和儲存）
 - 設計擔憂為了每個層
 - 非均勻記憶使用權（非均勻記憶體存取）
- 進步研究主題：
 - （1）主記憶體擴展
 - （2）重新考慮頁面大小
 - （3）重新思考頁過錯處理程式




I/O 裝置和I/O 系統

- 如何數據儲存在輸入/輸出裝置：
 - 基於NAND快閃記憶體堅硬的狀態駕駛（固態硬碟）
 - 難的磁碟駕駛（硬碟）
 - 帶瓦片磁的駕駛（SMR）
- 裝置司機
 - 更多的關於中斷：上半部對比下半部
 - 如何寫入裝置司機
- 堵塞輸入/輸出層
 - BIO是什麼
 - 合併和聚結 I/O 操作
 - I/O調度程序
- 進步話題：
 - NVMe 協定
 - 裝置映射器



文件系統

- 虛擬的文件系統
- 文件系統
 - 組織（檔案和目錄）
 - 介面（功能）
- 頁快取
 - 快取驅逐（Linux 雙列表戰略）
 - 這沖洗器執行緒
- 記憶對應（mmap）
- 進步研究話題：
 - 記憶體中文件系統



應用（選修的）

- 圖形系統
 - 如何到跑步圖形系統在個人的計算機（GraphChi）
 - 如何到流程動態圖（GraphOne）
- 深度推薦系統
 - 一般的推薦系統（Facebook DLRM）
 - 基於GNN社會的推薦系統（金東GraphRec）
- 鍵值資料庫（用於儲存）
 - 日誌結構合併 (LSM) 資料庫（Google）
 - 雷射掃描模組在固態硬碟（威斯康辛州）
 - 學習指數
- 資料中心（雲端）計算
 - 數據重複資料刪除
 - 記憶體檔案系統
 - 分散式文件系統（頭孢）
- 虛擬化概念

感謝您的關注 問答



Thank you